

TECH CHALLENGE - FASE 3

Assistente Clínico com LLM

Fine-tuning com QLoRA, RAG, LangChain, LangGraph e guardrails de segurança

Curso	Pós IA para DEVs / FIAP
Fase	Fase 3
Tema	Assistente clínico com LLM customizada e fluxo automatizado
Integrante	Diogo da Silva Souza
Repositório GitHub	https://github.com/Diogosouza3101/tech-challenge-FIAP-fase3-assistente-medico
Adapter Fine-Tuned	https://huggingface.co/Diogossouza/qwen2.5-3b-medical-fiap-lora
Vídeo de demonstração	https://youtu.be/hHx6r9znYAw

Setembro/2026

Resumo Executivo

Este relatório apresenta a solução desenvolvida para o Tech Challenge da Fase 3 da pós-graduação em IA para DEVs. O trabalho implementa um assistente clínico acadêmico de apoio à decisão, combinando uma LLM customizada por fine-tuning com dados sintéticos, consulta estruturada a pacientes, recuperação de protocolos por RAG, orquestração de fluxo com LangGraph, validação determinística de segurança e rastreabilidade por logs.

O modelo base selecionado foi o Qwen2.5-3B-Instruct. O ajuste foi realizado localmente com QLoRA em quantização 4-bit NF4, utilizando 60 exemplos conversacionais curados, sendo 40 destinados ao treino e 20 à validação. O treinamento ocorreu por três épocas em uma NVIDIA GeForce RTX 3060 de 12 GB, com apenas 0,9607% dos parâmetros reportados como treináveis por meio do adapter LoRA.

Na avaliação manual de dez cenários, o modelo base obteve 48 pontos de 80 possíveis (60,00%), enquanto o modelo fine-tuned alcançou 53 de 80 (66,25%), melhoria de 6,25 pontos percentuais. Essa pontuação mede aderência à rubrica definida para segurança, validação médica, aderência a protocolo e rastreabilidade; não representa acurácia diagnóstica ou validação clínica.

A aplicação final integra Streamlit, LangChain, SQLite, FAISS e LangGraph. O assistente consulta dados do paciente, recupera protocolos internos fictícios, gera uma resposta contextualizada, executa uma checagem determinística de possível prescrição ou dosagem e registra a interação. O sistema é exclusivamente acadêmico e não deve ser usado para diagnóstico, prescrição ou tomada de decisão médica real.

Sumário

1. Introdução
2. Objetivo do projeto
3. Escopo e aderência ao desafio
4. Dados utilizados e preparação
5. Processo de fine-tuning da LLM
6. Avaliação do modelo e análise dos resultados
7. Arquitetura da solução
8. Assistente clínico: LangChain, banco de dados e RAG
9. Orquestração com LangGraph
10. Segurança, explainability e logging
11. Interface e demonstração funcional
12. Organização, reprodutibilidade e publicação dos artefatos
13. Discussão crítica e limitações
14. Conclusão
15. Referências e links

1. Introdução

O cenário proposto para a Fase 3 evolui o uso de Inteligência Artificial no ambiente hospitalar para um assistente virtual capaz de utilizar conhecimento institucional, consultar informações de pacientes e organizar fluxos automatizados de decisão. A solução deve combinar customização de LLM, integração com bases estruturadas, contextualização com protocolos internos e mecanismos de segurança e auditoria.

Neste projeto, o problema foi tratado como uma prova de conceito de assistência clínica em contexto de investigação de alterações mamárias. Foram utilizados apenas pacientes e protocolos fictícios. A proposta não é produzir diagnóstico definitivo, mas demonstrar como uma LLM ajustada pode receber dados de um paciente, recuperar informações institucionais relevantes e responder de forma mais controlada e rastreável.

Uma LLM de uso geral pode acrescentar informações ausentes, interpretar incorretamente exames pendentes como resultados já disponíveis ou responder a solicitações inadequadas de prescrição e dose. Por esse motivo, a arquitetura foi construída em camadas: comportamento aprendido no fine-tuning, recuperação de contexto por RAG, fluxo controlado por LangGraph, consulta estruturada ao banco, guardrail determinístico e logging.

2. Objetivo do projeto

O objetivo principal é construir um assistente clínico acadêmico capaz de consultar um paciente por identificador, recuperar protocolos pertinentes, gerar uma resposta contextualizada com uma LLM customizada e submeter a resposta a verificações de segurança antes de apresentá-la ao usuário.

- Realizar fine-tuning de uma LLM com exemplos médicos sintéticos e curados.
- Integrar a LLM customizada a um fluxo de consulta estruturada de pacientes.
- Aplicar RAG para recuperar protocolos internos fictícios e disponibilizar suas fontes.
- Orquestrar as etapas do assistente com LangGraph.
- Definir limites de segurança para impedir respostas contendo possíveis prescrições ou dosagens.
- Registrar as interações para rastreabilidade e auditoria técnica.
- Disponibilizar uma interface Streamlit para demonstração do fluxo ponta a ponta.

3. Escopo e aderência ao desafio

O enunciado da Fase 3 exige fine-tuning de LLM, uso de dados médicos preparados e anonimizados ou sintéticos, integração com LangChain, consulta a dados estruturados, contextualização das respostas, segurança, logging, explainability, organização modular em Python, fluxo com LangGraph, relatório técnico e vídeo de demonstração. A implementação foi estruturada para cobrir esses componentes.

Requisito	Implementação	Evidência no projeto
Fine-tuning de LLM	Qwen2.5-3B-Instruct ajustado com QLoRA/LoRA.	Notebook 05 e adapter publicado no Hugging Face
Preprocessing, anonimização e curadoria	Uso de dados totalmente sintéticos, revisão de duplicidades e divisão treino/validação.	Notebooks 01, 02 e 03
LangChain + base estruturada	Integração com SQLite/SQLAlchemy nos notebooks e consulta parametrizada na aplicação.	Notebooks 07/08/10 e src/database
Contextualização	RAG com embeddings multilíngues e FAISS sobre protocolos fictícios.	Notebook 09/10 e src/chains
Segurança	Fine-tuning com exemplos de recusa + guardrail determinístico.	Notebook 06/10 e src/safety

Requisito	Implementação	Evidência no projeto
Logging e auditoria	Registro UTF-8 com timestamp, paciente, pergunta, protocolos e status.	src/utils/logger.py
Explainability	Exibição dos dados usados e fontes dos protocolos recuperados.	Streamlit e metadados do RAG
LangGraph	Fluxo START -> validação -> consulta -> RAG -> geração -> segurança -> log -> END.	src/graph/medical_graph.py

4. Dados utilizados e preparação

Foram utilizados exclusivamente dados sintéticos e protocolos institucionais fictícios, evitando qualquer exposição de informações pessoais ou prontuários reais. A solução possui quatro pacientes sintéticos, cinco protocolos e um dataset conversacional para fine-tuning.

Artefato	Conteúdo	Finalidade
pacientes.csv	4 pacientes sintéticos (PAC001 a PAC004)	Contexto estruturado do paciente
protocolos_medicos.json	5 protocolos fictícios (PROTO-001 a PROTO-005)	Base de conhecimento do RAG
hospital.db	Tabela pacientes em SQLite	Consulta estruturada
fine_tuning_medico.jsonl	60 exemplos conversacionais	Dataset completo do ajuste
train.jsonl	40 exemplos	Treinamento
validation.jsonl	20 exemplos	Validação

O dataset de fine-tuning foi organizado em dez categorias, cada uma com seis exemplos, cobrindo comportamentos relevantes para um assistente clínico educacional. O objetivo da curadoria foi ensinar o modelo a responder de forma prudente, reconhecer ausência de dados, evitar diagnóstico definitivo e preservar a necessidade de validação humana.

- alteracao_suspeita
- historico_familiar
- exames_pendentes
- prescricao
- dosagem
- diagnostico_definitivo
- informacao_insuficiente
- rastreabilidade
- acompanhamento
- encaminhamento

Durante a preparação, foram verificadas duplicidades completas e a divisão entre treino e validação foi revisada para evitar perguntas idênticas compartilhadas entre os dois conjuntos. A partição final contém 40 exemplos de treino e 20 de validação, sem perguntas idênticas entre as partições. Por se tratar de um dataset pequeno e sintético, essa separação reduz vazamento direto, mas não elimina a similaridade temática e textual entre exemplos da mesma categoria.

5. Processo de fine-tuning da LLM

5.1 Modelo e estratégia de ajuste

O modelo base escolhido foi o Qwen/Qwen2.5-3B-Instruct. O tamanho de aproximadamente 3 bilhões de parâmetros oferece um compromisso adequado entre capacidade de linguagem e viabilidade de treinamento e inferência em hardware local. Para reduzir o consumo de memória, foi utilizada a técnica QLoRA, que mantém o modelo base quantizado em 4 bits e treina adapters LoRA de baixa dimensão.

Configuração	Valor
Modelo base	Qwen/Qwen2.5-3B-Instruct
Técnica	QLoRA com adapter LoRA via PEFT
Quantização	4-bit NF4 com double quantization
Tipo de cálculo	torch.bfloat16
Épocas	3
Treino / validação	40 / 20 exemplos
LoRA r / alpha / dropout	16 / 32 / 0,05
Módulos alvo	all-linear
Batch / acumulação de gradiente	1 / 4 passos
Learning rate	1e-4
Comprimento máximo	512 tokens
Parâmetros treináveis	29.933.568 (0,9607% dos parâmetros reportados)
Hardware	NVIDIA GeForce RTX 3060 - 12 GB VRAM

5.2 Evolução do treinamento

Época	Training loss	Validation loss	Mean token accuracy
1	1,225413	1,034851	0,802590
2	0,504171	0,484138	0,898021
3	0,400266	0,432539	0,900814




Figura 1 - Evolução das losses registradas durante as três épocas de fine-tuning.

A loss de treino e a loss de validação diminuíram ao longo das três épocas. A validation loss passou de 1,034851 para 0,432539 e permaneceu próxima da training loss ao final do treinamento, sem evidência clara de divergência entre as curvas nesse intervalo curto. A métrica mean token accuracy aumentou para aproximadamente 0,90, mas deve ser interpretada apenas como uma métrica de predição de tokens no dataset de validação, e não como acurácia clínica ou diagnóstica.

Importante: o fine-tuning melhora o comportamento observado nos exemplos avaliados, mas não garante segurança clínica. Por isso, a arquitetura final adiciona RAG, regras explícitas e guardrails determinísticos.

6. Avaliação do modelo e análise dos resultados

A comparação entre o modelo base e o modelo fine-tuned foi realizada em dez casos representativos das categorias do projeto. Cada resposta recebeu nota de 0 a 2 em quatro critérios: segurança, validação médica, aderência ao protocolo e rastreabilidade. O máximo possível foi de oito pontos por caso e 80 pontos no conjunto completo.

Modelo	Pontuação manual	Percentual da pontuação máxima
Modelo base	48/80	60,00%
Fine-tuned	53/80	66,25%




Figura 2 - Comparação da pontuação manual entre o modelo base e o modelo fine-tuned.

O fine-tuned apresentou ganho de 6,25 pontos percentuais na rubrica manual. O resultado indica melhoria de aderência ao comportamento desejado no pequeno conjunto de testes, mas não permite afirmar generalização, segurança clínica ou superioridade estatística. A avaliação contém apenas dez casos e foi realizada antes da integração final com RAG e guardrail.


Um teste de estresse relacionado a prescrição e dosagem evidenciou uma diferença relevante: o modelo base iniciou a resposta com uma recusa, mas em seguida apresentou informações de medicamentos e doses; para a mesma intenção, o modelo fine-tuned manteve a recusa e direcionou a decisão ao profissional médico. Essa evidência é pontual e motivou a adoção de uma camada determinística adicional de segurança.

Interpretação: 66,25% é a proporção da pontuação máxima obtida na rubrica manual. Esse valor não deve ser chamado de acurácia do modelo.

7. Arquitetura da solução

A arquitetura combina componentes de consulta estruturada, recuperação de conhecimento, geração com LLM fine-tuned, validação de segurança e rastreabilidade. O LangGraph atua como orquestrador do fluxo e controla as transições entre as etapas.

Arquitetura da Solução — Assistente Clínico com IA



A ferramenta atua como apoio à decisão e não substitui a avaliação médica.

Figura 3 - Arquitetura da solução e fluxo principal do assistente clínico. Fonte: elaboração própria.

8. Assistente clínico: LangChain, banco de dados e RAG

8.1 Consulta estruturada de pacientes

Nos notebooks de integração, o LangChain Community foi utilizado com SQLiteDatabase e SQLite/SQLAlchemy para demonstrar a consulta à base estruturada. Na aplicação modular final, a consulta foi endurecida: o módulo `src/database/database.py` utiliza `sqlite3` com SQL fixo e parametrizado, banco aberto para leitura e filtro pelo ID informado. A LLM não recebe permissão para gerar SQL livremente.

O identificador do paciente é normalizado e validado no padrão PAC seguido de três dígitos. O contexto retornado contém ID, idade, sexo, histórico familiar, resultado do exame já realizado, exame pendente e status. Uma regra importante da aplicação é manter separadas as informações de exame concluído e exame pendente, reduzindo o risco de interpretar uma pendência como achado já confirmado.

8.2 Recuperação aumentada por geração (RAG)

Os cinco protocolos fictícios são convertidos em documentos LangChain com ID, título, conteúdo e metadados de fonte. Os embeddings são produzidos pelo modelo `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` por meio de `HuggingFaceEmbeddings` e indexados em FAISS em memória.

Protocolo	Tema	Papel no fluxo
PROTO-001	Alteração mamária suspeita	Avaliação inicial dos achados e necessidade de avaliação especializada.
PROTO-002	Histórico familiar e fatores de risco	Contextualização de risco sem conclusão diagnóstica isolada.
PROTO-003	Exames pendentes	Incluído obrigatoriamente quando existe exame pendente.
PROTO-004	Segurança na recomendação clínica	Sempre incluído para reforçar limites de atuação.
PROTO-005	Rastreabilidade	Sempre incluído para orientar fontes e auditoria.

A busca semântica recupera inicialmente três documentos ($k=3$), combinando a pergunta com o contexto do paciente. Em seguida são aplicadas regras de inclusão obrigatória: PROTO-003 quando há exame pendente e, em todos os casos, PROTO-004 e PROTO-005. Assim, o conjunto final pode conter mais de três protocolos.

A estratégia híbrida foi escolhida porque a similaridade vetorial, isoladamente, pode deixar de recuperar um documento crítico de segurança. As regras determinísticas garantem que protocolos considerados essenciais estejam presentes no contexto final.

9. Orquestração com LangGraph

O LangGraph organiza o assistente como um fluxo de estados. Cada nó executa uma responsabilidade delimitada e o estado transporta a pergunta, o ID do paciente, os dados consultados, os protocolos recuperados, a resposta, o status de segurança e mensagens de erro.

Etapas	Nó	Responsabilidade
1	Validar entrada	Verifica pergunta e formato do ID.
2	Consultar paciente	Busca o registro solicitado no SQLite.
3	Recuperar protocolos	Executa o RAG e as inclusões obrigatórias.
4	Gerar resposta	Carrega Qwen base + adapter LoRA e gera texto contextualizado.
5	Validar segurança	Executa o guardrail sobre a resposta gerada.
6	Registrar log	Registra metadados, fontes e status.

Etapa	Nó	Responsabilidade
7	Finalizar	Retorna resposta, dados, fontes e status à interface.

Entradas inválidas, perguntas vazias e pacientes inexistentes são desviados para o registro de log sem executar geração. Quando o guardrail bloqueia a resposta, o conteúdo original não é apresentado na interface; o usuário recebe uma mensagem de bloqueio e o motivo associado.

10. Segurança, explainability e logging

10.1 Camadas de segurança

A solução utiliza duas camadas complementares. A primeira é comportamental: o dataset de fine-tuning contém exemplos que ensinam o modelo a recusar prescrição, dosagem e confirmação diagnóstica definitiva, além de exigir dados suficientes e validação médica. A segunda é determinística: o módulo de guardrail inspeciona a resposta antes de sua exibição.

O guardrail procura números associados a unidades de dosagem como mg, mcg, g, ml e mg/m², além de expressões como “prescrevo”, “recomendo tomar”, “deve tomar” e “a dose recomendada é”. Quando encontra um padrão, o status é definido como bloqueado e a resposta original é substituída por uma mensagem de segurança.

Limite do guardrail: o status “aprovado” significa somente que os padrões implementados não foram detectados. Isso não garante correção médica, ausência de alucinação ou segurança clínica completa.

10.2 Explainability e rastreabilidade

A interface apresenta os dados do paciente efetivamente utilizados, os protocolos recuperados, as fontes correspondentes, a resposta final e o status de segurança. Essa transparência permite ao usuário verificar qual contexto foi fornecido ao modelo. Trata-se de explainability operacional e de rastreabilidade de contexto; não é uma explicação dos mecanismos internos da rede neural.

O log é gravado em UTF-8 e contém timestamp, ID do paciente, pergunta, IDs dos protocolos, status e eventual motivo de bloqueio. Rotas de erro de entrada também são registradas. O log não armazena o texto completo da resposta e não deve ser interpretado como um prontuário ou sistema completo de auditoria clínica.

11. Interface e demonstração funcional

A aplicação Streamlit permite informar um ID de paciente e uma pergunta clínica. Ao acionar a análise, o fluxo consulta o banco, recupera protocolos, gera a resposta, aplica a validação de segurança, registra o log e apresenta o resultado em blocos separados.

- Dados utilizados na geração.
- Protocolos e fontes recuperados pelo RAG.
- Resposta contextualizada da LLM fine-tuned.
- Status final de segurança.

Um caso de demonstração utilizado no projeto é o paciente PAC001, com pergunta de análise da situação atual e identificação dos pontos que precisam de atenção. O fluxo recupera o contexto estruturado, inclui protocolos relevantes e apresenta a resposta sem transformar exame pendente em resultado confirmado.

Também foi testada uma solicitação de prescrição e dose. Quando a LLM fine-tuned responde com uma recusa segura, o guardrail pode retornar “aprovado”, pois sua função é avaliar a resposta produzida, e não

punir a intenção inadequada da pergunta. Se a resposta contiver padrão de possível prescrição ou dose, o status é “bloqueado”.

12. Organização, reprodutibilidade e publicação dos artefatos

O projeto foi organizado em notebooks experimentais e módulos Python para execução da aplicação. Os notebooks 00 a 10 registram a evolução do ambiente, preparação de dados, modelo base, fine-tuning, avaliação, banco de dados, RAG e integração do assistente. A pasta src concentra a versão modular utilizada pelo Streamlit.

Componente	Responsabilidade
src/llm/model.py	Carregamento do Qwen quantizado e adapter LoRA
src/database/database.py	Consulta parametrizada ao SQLite
src/chains/medical_rag.py	Embeddings, FAISS e recuperação de protocolos
src/graph/medical_graph.py	Fluxo LangGraph e rotas
src/safety/guardrails.py	Validação determinística de segurança
src/utils/logger.py	Registro UTF-8 das interações
app/app.py	Interface Streamlit

Os pesos do adapter não foram versionados diretamente no GitHub. O arquivo adapter_model.safetensors e checkpoints locais são ignorados pelo .gitignore, evitando envio de artefatos pesados. O adapter final foi publicado separadamente no Hugging Face, enquanto o repositório GitHub contém código, metadados, datasets sintéticos, banco SQLite, notebooks e resultados da avaliação.

GitHub: <https://github.com/Diogosouza3101/tech-challenge-FIAP-fase3-assistente-medico>

Hugging Face: <https://huggingface.co/Diogossouza/qwen2.5-3b-medical-fiap-lora>

Para executar a aplicação, o ambiente validado utiliza Python 3.11, PyTorch com CUDA compatível, Transformers, PEFT, bitsandbytes, LangChain, LangGraph, sentence-transformers, FAISS, Streamlit, pandas e SQLAlchemy. O caminho validado foi executado em GPU NVIDIA; não foi validado um fallback completo de inferência em CPU.

13. Discussão crítica e limitações

Os resultados mostram que o fine-tuning foi capaz de melhorar a aderência da LLM a comportamentos desejados no conjunto avaliado. A integração com RAG também reduz a dependência exclusiva do conhecimento paramétrico do modelo, permitindo fornecer protocolos específicos e fontes visíveis ao usuário. O LangGraph torna o processo mais previsível ao separar validação, consulta, recuperação, geração, segurança e logging em etapas explícitas.

Apesar disso, a solução permanece uma prova de conceito. O dataset possui apenas quatro pacientes sintéticos, cinco protocolos e 60 exemplos de fine-tuning. A avaliação manual cobre dez casos e não representa validação clínica, estudo estatístico ou teste de generalização. O guardrail é baseado em padrões e pode gerar falsos positivos ou deixar passar formulações não previstas. O RAG melhora a disponibilidade de contexto, mas não garante que todas as afirmações da LLM estejam apoiadas pelas fontes recuperadas.

- Dados e protocolos totalmente sintéticos, sem validação em prontuários reais.
- Pequeno volume de dados para fine-tuning e avaliação.
- Possibilidade de alucinação, omissão ou interpretação incorreta do contexto.

- Guardrail baseado em expressões regulares e padrões limitados.
- Ausência de autenticação, autorização e governança necessárias para uso com dados reais.
- Dependência de GPU e compatibilidade de versões do ambiente local.
- Necessidade de validação humana em qualquer resposta clínica.

14. Conclusão

O Tech Challenge da Fase 3 resultou em uma solução funcional de assistente clínico acadêmico baseada em LLM customizada. O projeto implementou o fine-tuning do Qwen2.5-3B-Instruct com QLoRA, criou uma base sintética de pacientes e protocolos, integrou consulta estruturada, RAG, LangChain e LangGraph, e adicionou mecanismos de segurança, logging e rastreabilidade.

A avaliação manual mostrou aumento de 60,00% para 66,25% da pontuação máxima após o fine-tuning, com melhoria observável em cenários de segurança. A arquitetura final amplia esse controle ao combinar o comportamento aprendido com recuperação de protocolos e validação determinística da resposta.

Do ponto de vista técnico, a principal contribuição do trabalho é demonstrar uma arquitetura em camadas, na qual a LLM não atua isoladamente. Dados estruturados, fontes recuperadas, regras de fluxo, guardrails e registros de auditoria são tratados como componentes complementares. Para qualquer aplicação real na saúde, seriam indispensáveis validação clínica, maior escala de dados, testes de segurança, governança, controle de acesso, privacidade e supervisão profissional.

15. Referências e links

FIAP - Tech Challenge Fase 3: Enunciado oficial disponibilizado no curso Pós IA para DEVs.

Modelo base: Qwen/Qwen2.5-3B-Instruct - Hugging Face.

Repositório do projeto: <https://github.com/Diogossouza3101/tech-challenge-FIAP-fase3-assistente-medico>

Adapter fine-tuned: <https://huggingface.co/Diogossouza/qwen2.5-3b-medical-fiap-lora>

Evidências experimentais: Notebooks 00_teste_ambiente.ipynb a 10_assistente_rag.ipynb e arquivos CSV em data/processed/.

Aviso acadêmico: este sistema é destinado exclusivamente à demonstração educacional. Não deve ser utilizado para diagnóstico, prescrição, definição de doses ou tomada de decisão médica real. Os pacientes e protocolos são fictícios e a ferramenta não substitui a avaliação de um profissional médico.